

2026-09-04

今朝のホットな話題

1. GPT-6 Astra
2. Cursorの自社マシン実行
3. Codex CLI 0.153.0

注目3件


GPT-6 Astra

長期作業の文脈を「圧縮」から「記録と検索」へ

OpenAIはGPT-6 Astraの段階提供を始めた。

- 一部組織から始め、今後数日でChatGPT Plus、Pro、Business、Enterprise、API、Amazon Bedrockへ広げる
- APIのモデルIDはgpt-6-astra。標準価格は100万トークン当たり入力10ドル、出力50ドル
- Codexでは過去の文脈窓を検索でき、従来のcompactionで落ちやすかった失敗理由や要件を取戻せる

圧縮



記録と検索




長時間エージェントは、作業の経緯と検証結果を失わずに終わられるかで評価する。

Cursorの自社マシン実行

コードは社内、推論はクラウド

CursorはCloud Agentsのファイル編集やコマンド実行を、利用者が管理するマシンで動かせるようにした。

- 自社workerからCursorクラウドへ外向きのHTTPS接続を張り、Cursor側から社内ネットワークへの接続開始を避ける
- 個人向けのMy Machinesと、需要に応じてworkerを増減するチーム向けPoolsを提供
- workerの休止とスナップショット復帰に対応し、フォローアップ待ちの計算資源を抑えられる



企業が確認すべき境界は、「セルフホスト」という呼称より、コード、シークレット、ツール出力、会話、推論がそれぞれどこを通るかだ。

Codex CLI 0.153.0

切断後も二重実行せずに戻る

OpenAIはCodex CLI 0.153.0で、リモートマーケットプレイスからプラグインを管理するCLIと、アプリサーバー切断後のセッション再接続を追加した。

- プラグインの一覧、導入、削除をCLIから行える
- 再接続時に下書きと会話を保ち、結果が不明な要求は確認待ちに置く
- Guardianのレビュー履歴をcompaction、再起動、フォークをまたいで維持する




長時間エージェントでは、新機能よりも再接続と重複防止が運用品質を左右する。

Qwen3.8-Max

2.4兆パラメーターで10日超の開発を掲げる

Alibaba CloudはQwen3.8-Maxを2.4兆パラメーターのMoEモデルとして公開した。

- 国際向けモデルIDはqwen3.8-maxで、東京、バージニア、フランクフルトなどから利用できる
- Function Calling、Structured Outputs、Context Caching、Prefix Completionに対応
- 中国リージョンと国際リージョンでは、Web SearchやBatch Inferenceなどの対応範囲が異なる




長く動いたことと、仕事を正しく終えたことは別だ。

Microsoftのコンテキスト設計

安いモデルより先に、毎回送る情報を減らす

Microsoftは、モデルが毎ターン見る指示、ツール、文書、履歴を選び直すことを、エージェントの費用と品質を改善する中心手段に挙げた。

- モデル自体は記憶を持たず、毎ターンのコンテキスト再送が長期タスクの費用を膨らませる
- 実行履歴、利用可能な情報、ツールの一覧は、作業が続くほど増える
- 情報量を増やしても品質は保証されず、関連性と検索しやすさが重要になる




モデルの単価を比べる前に、毎ターン送る文書とツール定義を見直せる。

ループエンジニアリング

GitHubが示す「合格と停止」の設計

GitHubはループエンジニアリングを、単発の指示から、エージェントを囲む反復可能な仕組みへ移す実践として整理した。

- Ralph loopをplan、act、checkの反復例とし、文脈や計算資源を消費する限界も示す
- Skills、観測性、検証、ルーティング、チェックポイントを加えて単なる再試行と分ける
- squadは役割を分けた複数エージェント、fleetは並列実行を指す



ループの本体は、成功するまで同じ指示を回すことではない。

Databricksの2万組織調査

本番化を分けるのは評価とガバナンス

Databricksは自社のData + AI Platformを使う2万超の組織を対象に、AIエージェントの利用状況をまとめた。

- 対象は世界2万超の利用組織で、Fortune 500の60%超を含むとDatabricksが説明
- 複数エージェントシステムは4カ月未満で327%増加
- 評価ツールを使う企業はAIプロジェクトの本番化が約6倍と報告




デモやエージェント数を増やすだけでは本番化につながらない。

ひとりソフトウェアファクトリー

コードを読まなくても、ゲートは二重にする

溝口浩二氏は、1人でCodexとClaude Codeを使い、Artifact Shareを開発する工程と実績を公開した。

- 4カ月でTypeScript約25万行、Pull Request 1,144件、Issue 777件に達した
- 公開後4週間で233件をマージし、revertは0件、本番不具合は9件だった
- 仕様と実装をCodexとClaude Codeで並列レビューし、両方のblockerがゼロになるまで回す



コードを読む作業を減らしても、品質確認は残る。

本日のトピック一覧

1. GPT-6 Astra
2. Cursor Self-Hosted Machines
3. Codex CLI 0.153.0
4. Qwen3.8-Max
5. Microsoftのコンテキスト設計
6. GitHubのループエンジニアリング
7. Databricksの2万組織調査
8. ひとりソフトウェアファクトリー