

2026-09-14

外部評価者の受け入れ方針
レビューと利用状況の更新
少人数でAIを運営する事例

7件

Anthropicの外部評価方針

社員に近いアクセスで継続的な検査を受ける方針。

- 外部評価者による安全対策・事故・訓練過程の検査
- 不利な評価結果も原則として公表できる契約を想定
- 業界・国家間の調整は今後の提案



安全対策を誰が検査するかも比較材料に。

修正済みの指摘を閉じる

Copilotが再レビュー時に解決済みを判断。

- 再レビューで修正済みと判断した指摘を解決済みに
- 未対応の指摘は開いたまま残す
- ビルド・テストを含む検証手段を拡大




残った指摘と実際の修正結果を確かめる。

専用Agents画面の利用状況

人数・セッション数・メッセージ数が集計対象に。

- 専用Agentsウィンドウの活動が対象
- 該当データがなければ項目なし、またはnull
- 閲覧権限と利用状況計測ポリシーの有効化が必要



利用回数と仕事の成果を合わせて見る。

利用者のIDでAIへ接続

Apertureが社内ネットワークと利用権限を連動。

- 利用者の追加・削除とAIアクセスを連動
- モデルごとの費用と使用量を共通の接続口で取得
- 実行用Sandboxもネットワーク上のIDで確認



人やAIが増えても鍵を配る負担を減らす。

3人で広報AIを運営

Featuredの構築事例。数字は同社の申告値。


- 17モデルへの接続処理を共通化
- 長時間の調査や候補選別をWorkflow SDKで実行
- 会話中心の画面への改修を約1週間で実施と説明

独自のデータと業務設計に時間を割く。

作ったサイトをSNSへ紹介

Netlifyの共有ボタンでリンク付きの投稿画面へ。

- 5つのSNSに対応
- プロジェクトのリンクを投稿画面へ引き継ぐ
- 投稿する内容は送信前に確認



内容と公開範囲を確認してから紹介する。

改善を別の課題でも試す

〈知見〉 HarnessDevの研究は9月1日公開。

- 構築実験は6モデル・5ベンチマーク・2,207課題
- 最終版が未使用課題でも最良だったのは9系列中2系列
- 実行モデルを替えると改善の結果も変わる

別の課題でも成功率と利用量を比べる。

本日のトピック一覧

1. Anthropicの外部評価方針
2. 修正済みの指摘を閉じる
3. 専用Agents画面の利用状況
4. 利用者のIDでAIへ接続
5. 3人で広報AIを運営
6. 作ったサイトをSNSへ紹介
7. 改善を別の課題でも試す