

2026-10-07


1. Mistral Large 4、APIプレビューを開始
2. Beam、コードと推論を担う公開モデルを予告
3. Claude Code 2.1.292、委任時の思考量を指定

注目3件

Mistral Large 4、APIプレビューを開始

Mistralは、文章と画像を扱うMistral Large 4のAPIプレビューを始めました。

- 総パラメータ数1兆、処理時に使うのは490億
- コード作成・業務エージェント・画像理解を対象
- Vercel AI Gatewayからも利用可能




手元の文章や画像を使う業務で、既存モデルと同じ課題を解かせる比較候補になります。

Beam、コードと推論を担う公開モデルを予告

Reflectionは、コード作成や推論に向けた最初のモデルBeamを紹介しました。

- 総パラメータ数5010億、処理時に使うのは230億
- 文章を扱うモデルで、画像理解モデルではない
- 重み・技術報告・評価と追加学習の道具を公開予定



公開後に、自社の開発課題で精度と実行費用を調べる材料になります。

Claude Code 2.1.292、委任時の思考量を指定

Claude Code 2.1.292は、Agentツールにeffort引数を追加しました。

- プラグイン導入時にマーケットプレイスを指定可能
- 再開後の定期タスクやバックグラウンドのループを修正
- ファイル参照・管理設定に関する権限制御も修正




短い調査と難しい設計で、委任先の思考量を分ける選択肢が増えます。

AI Gateway、不確かな判断だけ別モデルへ

Vercel AI Gatewayは、判断モデルの回答が指定した確信度の条件に触れたとき、別モデルへ判断を回す機能をベータ公開しました。

- Choice・Scoreは確信度、Booleanは確率の範囲を条件にする
- 複数の条件を組み合わせられる
- 切り替えた場合は両段階の処理が課金対象



問い合わせの振り分けなどで、判断が難しい入力だけ追加の処理へ回せます。

GitHub、LovableとSupabaseの 秘密情報を検出

GitHubのSecret scanningが、Lovable、Pydantic、Supabaseの新しい認証情報の形式に対応しました。

- LovableのAPIキーを追加
- PydanticのLogfireとAI Gatewayのキーを追加
- SupabaseのOAuthと権限を絞った個人トークンを追加



AIで作ったアプリのコードに、接続用のキーを残してしまう事故の発見に役立ちます。

GPT-6 AstraとSol、サブスク経由の速度を改善

OpenAIのTiboは、サブスクリプション経由のGPT-6 AstraとGPT-6.1 Solの標準速度を約50%高速化したと報告しました。

- OpenCode・Pi・Amp・Devinなどを対象として例示
- 返信では毎秒30から50トークンへの変化を説明
- API全体の速度改善を約束した発表ではない

毎秒30トークン



毎秒50トークン



AIへ頼む作業の待ち時間が減る可能性があります。

本日のトピック一覧

1. Mistral Large 4、APIプレビューを開始
2. Beam、コードと推論を担う公開モデルを予告
3. Claude Code 2.1.292、委任時の思考量を指定
4. AI Gateway、不確かな判断だけ別モデルへ
5. GitHub、LovableとSupabaseの秘密情報を検出
6. GPT-6 AstraとSol、サブスク経由の速度を改善